รายงานสถานะโดยละเอียด

Hybrid IDS สำหรับ Campus SOC

คอมเมนต์อาจารย์ · ปัญหาทีพบ · สิงทีแก้แล้ว · สิงทียังไม่แก้ และแนวทาง

ฉบับวันที 1 พฤศจิกายน 2569

สารบัญ

ส่วน	เนือหา	หน้า
1	คอมเมนต์อาจารย์ และสิงทีคอมเมนต์นันเปิดเผย	2
2	ปัญหาทีพบทังหมด — จัดกลุ่มตามความรุนแรง	3–4
3	สิงทีแก้แล้ว พร้อมหลักฐาน	5–6
4	สิงทียังไม่แก้ และแนวทางแก้	7–9
5	สิงทีแก้ไม่ได้ด้วยข้อมูลชุดนี (ข้อจำกัดเชิงโครงสร้าง)	10
6	ลำดับงานทีแนะนำ	11

หลักการเขียนรายงานนี

ทุกตัวเลขคัดลอกจากไฟล์ผลลัพธ์ที commit แล้วใน **reports/** หรือ **models/** ไม่มีการประมาณ

รายการ "ยังไม่แก้" แยกเป็นสองแบบทีต่างกันโดยสินเชิง: **(ก) แก้ได้แต่ยังไม่ได้ทำ** และ **(ข) แก้ไม่ได้ด้วยข้อมูล/ทรัพยากรทีมี** — การรวมสองแบบนีเข้าด้วยกันจะทำให้อ่านสถานะผิด

ข้อทีเป็น **trade-off ทีเลือกแล้ว** ไม่ใช่บัก ก็แยกไว้อีกกลุ่ม เพราะต้องรายงานในเล่ม ไม่ใช่รอแก้

1. คอมเมนต์อาจารย์ และสิ่งที่คอมเมนต์นั้นเปิดเผย

คอมเมนต์ที่ 1

"ไม่สามารถรวม unsupervised และ supervised dataset ได้ ดังนั้นไปพิจารณา dataset ที่นำมาใช้ และวิธีการวัดประสิทธิภาพใหม่ค่ะ"

คอมเมนต์นี้ถูกต้อง และกลไกมีอยู่จริง ไม่ใช่ความเข้าใจผิด:

โมเดล	อ่านชุดข้อมูล	จำนวน feature
Random Forest (supervised)	MachineLearningCSV	80
Isolation Forest + Autoencoder (unsupervised)	GeneratedLabelledFlows (behavioral)	92

สองชุดนี้เป็นการสกัดด้วย CICFlowMeter **สองครั้งแยกกัน** จาก capture เดียวกัน ไม่มีคีย์เชื่อม ต้องใช้ row-hash join ซึ่งจับคู่แถว BENIGN ได้ **76.4%** ทำให้ประเมิน ensemble ได้เพียง **80.36%** ของ test split แล้วเอาไปเทียบกับ RF ที่เห็นข้อมูล 100%

คอมเมนต์นี้เปิดเผยปัญหาที่ใหญ่กว่าที่ถาม

พอแก้การ join แล้ววัดใหม่อย่างยุติธรรม **กฎรวมผลที่ใช้อยู่เดิมกลายเป็นแพ้ Random Forest ตัวเดียว** จึงต้องเปลี่ยนสถาปัตยกรรมหลักของชั้น ML — ไม่ใช่แค่เปลี่ยนไฟล์ข้อมูล

สาเหตุที่แท้จริงคือ margin 9.3pp ของกฎเดิม **มาจากการที่ RF ถูกจำกัด feature ไว้** ไม่ใช่จากตัวกฎ การเทียบเดิมไม่เป็นธรรมกับ RF มาตลอด (พิสูจน์ด้วย ablation ในส่วน 3)

คอมเมนต์ที่ 2

"ทำไมเลือกใช้ ML สามตัวนี้ เพราะมันมีหลายโมเดลมาก"

คำตอบเดิม**อ่อน เพราะไม่เคยวัดคู่เทียบเลย** — การเลือก RF อาศัยความนิยมในงานวิจัย ไม่ใช่หลักฐานจากการทดลองของเราเอง

2. ปัญหาทีพบท้งหมด

กลุ่ม A — ปัญหาเชิงวิธีวิจัย (ทำให้ตัวเลขทีรายงานไม่ถูกต้อง)

#	ปัญหา	ผลกระทบ	สถานะ
A1	สอง population ต้อง join · coverage 80.36%	เทียบ ensemble กับ RF ไม่ยุติธรรม	แก้แล้ว
A2	LOAO normalize คะแนน test fold ด้วย min/max ของ test fold เอง	test distribution รั้วเข้าคะแนน · ทุก candidate สูงเกินจริง 1–4pp	แก้แล้ว
A3	normalization constants fit บน val ไม่ใช่ train (ae_max 0.811 เทียบค่าจริง 0.1225)	ถ้า deploy จะทำให้ ae_norm เล็กลง 6.6 เท่า · threshold ไม่มีทางถึง · detector เงียบโดยไม่มี error	แก้แล้ว
A4	SIEM baseline วัดบน test split คนละชุดกับ ensemble	ตารางหลักของ 4-way ablation เทียบของต่างชุดกัน	แก้แล้ว
A5	ข้อสรุป Option A ว่า behavioral features ไม่ช่วย RF	เป็นการให้เหตุผลตามหลักการ ไม่เคยวัด · วัดแล้วพบว่าผิด	แก้แล้ว
A6	in-dataset metric อิมตัว (RF val F1 0.9997)	แยกโมเดลไม่ออก ต้องใช้ zero-day LOAO เท่านั้น	ข้อจำกัด

กลุ่ม B — ปัญหาเชิงวิศวกรรม (โค้ดพังเงียบ หรือจะพังเมือ deploy)

#	ปัญหา	ผลกระทบ	สถานะ
B1	`model_used` whitelist ใน alert_dispatcher ไม่ตรงกับ fusion_layer	alert ทุกใบที branch นั้นตัดสินถูกติดป้าย "unknown" เงียบๆ	แก้แล้ว
B2	shap_explain เขียนไว้สำหรับกฎเดิม · ส่ง np.zeros แทนคะแนน IF	ถูกต้องตอนใช้ OR (IF ไม่มีผล) แต่ cascade ใช้ IF จริง □ attribution ผิดแบบดูไม่ออก	แก้แล้ว
B3	synthetic overlay สร้างใน 92-feature space ขาด Source Port / Protocol	โมเดลที deploy score overlay ไม่ได้เลย · M1b วัดไม่ได้	แก้แล้ว
B4	`mttd_seconds()` มีอยู่แต่ไม่มีสคริปต์ไหนเรียก	M1b อยู่ในรายการ metric แต่เป็นค่าว่าง	แก้แล้ว
B5	M1c ไม่มีโมเดลให้รัน (RF 80f score ชุด 76 คอลัมน์ไม่ได้)	M1c วัดไม่ได้	แก้แล้ว
B6	autoencoder_unified_config.json พา benign_row_count_reduction_pct 23.57 มาผิด	เลขนึกลับทิศกับความจริง (unified มี BENIGN มากกว่า) · เสียงหลุดเข้าเล่ม	แก้แล้ว
B7	random_forest_unified.pkl 108 MB เกินลิมิต GitHub	push พัง · เคยต้องล้าง history เพราะ blob 483 MB มาแล้ว	แก้แล้ว
B8	few-shot ใน prompt ถูกคัดลอกเข้า output 30/100 alert	คำอธิบายอ้าง IP/hostname ทีไม่มีใน alert จริง	แก้แล้ว
B9	eval_llm_faithfulness.py ยังโหลดโมเดลและ population ทีถูก supersede	ตัวเลข M2 ทีมีอยู่อธิบาย pipeline ทีไม่ได้ deploy แล้ว	ยังไม่แก้
B10	eda_sanity_check.py ยังอ่าน UNSW-NB15 รูปแบบเก่า 4 ไฟล์	รายงาน EDA ไม่ตรงกับสิงทีเข้า pipeline จริง	ยังไม่แก้

กลุ่ม C — อุบัติเหตุปฏิบัติการ

#	เหตุการณ์	ผล / บทเรียน	สถานะ
C1	`rm -rf` บน git worktree ทีมี Windows junction ชี้ไป data/	ลบทะลุ junction ทำลาย data/ จริง · ต้อง rebuild ทั้ง pipeline · กู้คืนได้เพราะทุกขั้นตอน pin random_state=42 (drift 0.00pp)	บันทึกแล้ว

บทเรียน C1 บันทึกไว้ใน CLAUDE.md แล้ว: ถ้าต้องแชร์ data/ เข้า worktree ให้ลบ junction ด้วย `rmdir` ห้ามใช้ `rm -rf` หรือดีกว่านั้นคือให้สคริปต์อ่าน absolute path ไม่ต้องสร้าง junction

3. สิ่งที่แก้แล้ว พร้อมหลักฐาน

3.1 แก้ที่ชั้นข้อมูล — เลิก join (A1)

	ก่อน	หลัง
จำนวน population	2 ชุด สกัดแยกกัน	1 ชุด
การ join	row-hash join จำเป็น	ไม่มีเลย
Coverage test split	**80.36%**	**100.00%**
Feature set	**RF 80 / IF+AE 92**	**94 ทุกโมเดล**
Train / Val / Test	ไม่ตรงกัน	1,780,362 / 504,192 / 504,193

สคริปต์: src/features/build_unified_population.py → src/modeling/train_unified_ensemble.py · คอลัมน์ระบุตัวตน 5 ตัวถูกตัดจาก input (Source IP จะทำให้โมเดลจำได้ว่า host ไหนโจมตี = leakage)

3.2 เปลี่ยนกฎรวมผล และพิสูจน์สาเหตุ (A5)

กฎ (nested LOAO)	F1	Recall	FPR
confidence_weighted ← ใช้จริง	**0.9782**	**0.9635**	**0.0007**
OR: RF หรือ AE (2 thresholds)	0.9745	0.9608	0.0011
RF ตัวเดียว	0.9737	0.9593	0.0011
OR: max(RF, AE) ← กฎเดิม	0.9724	0.9559	0.0010
AE ตัวเดียว	0.8736	0.8176	0.0055
IF ตัวเดียว	0.4371	0.4502	0.0619

ablation ที่พิสูจน์สาเหตุ — ตัดเฉพาะ 12 behavioral columns ออก

RF ตัวเดียว ในแต่ละเงื่อนไข	F1	Recall
unified 94 features (มี behavioral)	0.9737	0.9593
unified 82 features (ตัด behavioral)	0.8312	0.7942
population เก่าที่ join · 80 features	0.8327	0.7705

ตัด behavioral ออกแล้ว RF **ตกกลับไปทับ population เก่าแทบสนิท** (0.8312 เทียบ 0.8327) — สาเหตุคือ feature ไม่ใช่ population และไม่ใช่ตัวกฎ

ผลไม่สม่ำเสมอทุกหมวด: ที่ argmax behavioral columns ทำให้ RF แย่ลงบน DoS Slowhttptest (0.055 เทียบ 0.275) และ DoS slowloris (0.224 เทียบ 0.455) จึงต้องรายงานต่อหมวด

3.3 ตอบคอมเมนต์ที่ 2 ด้วยการวัด

โมเดล	เวลาเทรน	Inference 504k แถว	F1	AUC
Random Forest (sklearn, CPU)	**231.5 s**	**5.45 s**	**0.9997**	**1.0000**
XGBoost (GPU)	38.7 s	0.94 s	0.9907	0.9961

XGBoost ไม่ชนะด้านการตรวจจับ แต่ **เทรนเร็วกว่า 6 เท่า inference เร็วกว่า 5.8 เท่า** ที่ RF ช้าเพราะ scikit-learn ไม่มี GPU backend เลย — เป็นข้อจำกัดของไลบรารี ต้องรายงานคู่กัน

3.4 วิธีวัดใหม่ — 4-way ablation บน test split เดียวกัน (A4)

Arm	Precision	Recall	F1	FPR
Rule-based SIEM	0.8297	0.8980	0.8625	0.0375
Hybrid (confidence_weighted)	0.9952	0.9981	0.9966	0.00098
RF ตัวเดียว	0.9995	0.9995	0.9995	0.00009

n = 504,193 แถว ทุก arm · ค่ารวมของ SIEM หลอกตา: 8 จาก 14 หมวดได้ 0.000 เป๊ะ · rule R1 (port scan) ยิงโดนแถว attack ศูนย์แถว แต่สร้าง false positive 4,240 ครั้ง

3.5 metric ที่วัดครบในรอบนี้

Metric	ผล	ข้อควรระวังที่ต้องเขียนคู่กัน
M1a in-dataset	Hybrid F1 0.9966 · RF 0.9995	อิมตัว แยกโมเดลไม่ออก
zero-day LOAO	Hybrid F1 0.9782 · RF 0.9737	ส่วนต่างแค่ 0.45pp
M1b MTTD	c2_beacon 193 s · data_exfil 452 s	ค่าหลักเป็น 0.0000 s ซึ่ง degenerate ต้องใช้ค่าที่ตัด flow แรกออก
M1c cross-dataset	CICIDS□UNSW F1 0.0006 · UNSW□CICIDS 0.1139	พังทั้งสองทาง · AUC 0.3220 คือจัดอันดับกลับทิศ
SHAP faithfulness	RF 1.96e-10 · fallback 4.66e-09	latency 0.258 / 0.184 s ต่อ alert ไม่เหมาะ bulk

4. สิ่งที่ยังไม่แก้ และแนวทางแก้

แยกตามว่า**ทำเองได้ทันที** หรือ**ต้องรอทรัพยากรภายนอก** — เพราะสองอย่างนี้วางแผนต่างกัน

4.1 ทำเองได้ทันที — ควรทำก่อนส่งเล่ม

B9 · eval_llm_faithfulness.py อยู่บน pipeline ที่ถูก supersede [ความสำคัญ: สูง]

ปัญหา: สคริปต์โหลด **random_forest.pkl** (80f), **isolation_forest_behavioral_v2.pkl**, **autoencoder_behavioral_v2.pt** และอ่านไฟล์ feature สองชุดพร้อม row-hash join — ซึ่งเป็นสิ่งที่ unified population ยกเลิกไปแล้ว ค่า `model_used` ที่มันบันทึกคือ `autoencoder_v2` ซึ่งไม่มีอยู่อีกแล้ว

ผลคือ ตัวเลข M2 ที่มีอยู่ (entity preservation 28/100 ฯลฯ) อธิบาย pipeline ที่ไม่ได้ deploy — ยังอ้างในเล่มไม่ได้

แนวทาง: ย้ายไปอ่าน **cicids2017_unified_test.parquet** + โมเดล ***_unified** ทั้งสามตัว ตัด row-hash join ออก (ไม่ต้อง join แล้ว) และแก้การ recover IP/port/timestamp ให้ดึงจาก identifier columns ที่ unified population มีอยู่ตรงๆ แล้ววัด M2 ใหม่บน 100 alert

ประเมินเวลา: แก้สคริปต์ ~1 ชม. · รัน 100 alert ผ่าน Typhoon2 8B ~30–45 นาที

คุณภาพผลผลิต LLM ยังไม่ผ่านการตรวจ [ความสำคัญ: สูง]

สถานะ: โค้ดเสร็จและผ่าน 6 offline contract checks แต่ **quality_verified** ยังยืนยันบน alert จริงไม่เกิน 2 เคส และ **Ollama ไม่ได้รันอยู่** ตอนตรวจ (port 11434 ปิด) จึงวัดอะไรไม่ได้เลยในขณะนี้

ปัญหาที่วัดได้ก่อนหน้านี้และยังไม่ยืนยันว่าหายแล้ว: entity omission (ละ IP/port ที่ต้องมี) 72 จาก 100 เคสที่ fail · PortScan remediation แนะนำ WAF block ใน 5/7 เคส ซึ่งไม่ตรงกับลักษณะการโจมตี

แนวทาง: (1) start Ollama + ยืนยันว่า pull **scb10x/llama3.1-typhoon2-8b-instruct** แล้ว (2) แก้ B9 ก่อน (3) รัน M2 ใหม่ (4) ให้คนอ่านภาษาไทยประเมินเชิงคุณภาพ ตัวอย่างละ 20–30 เคสต่อหมวดสำคัญ — ข้อ (4) เป็นงานที่สคริปต์แทนไม่ได้

B10 · eda_sanity_check.py อ่าน UNSW รูปแบบเก่า [ความสำคัญ: ต่ำ–กลาง]

ปัญหา: ยังอ่าน **UNSW-NB15_1..4.csv** (รูปแบบ 4 ไฟล์ headerless) ขณะที่ pipeline จริงใช้ CIC-UNSW-NB15 (**Data.csv + Label.csv**) มาตั้งแต่ migration — รายงาน EDA จึงอธิบายข้อมูลที่ไม่ได้เข้า pipeline

แนวทาง: ชี้ `load_unsw` ไปที่ source เดียวกับ preprocess_pipeline (import มาใช้ซ้ำ ไม่เขียนใหม่เพื่อไม่ให้ drift) แล้ว regenerate eda_report.txt

ประเมินเวลา: ~30 นาที · **ความเสี่ยงถ้าไม่แก้:** ถ้าเล่มอ้างสถิติ EDA ของ UNSW จะเป็นสถิติของไฟล์ที่ไม่ได้ใช้

เอกสาร CLAUDE.md ย่อหน้า “Current implementation state” อ่านยาก [ความสำคัญ: ต่ำ]

> **ปัญหา:** ย่อหน้านี้เล่าประวัติ confidence_weighted □ rf_ae_or □ confidence_weighted ซ้อนกันสามชั้น ถูกต้องทุกคำแต่คนอ่านครั้งแรกจะสับสน และ notebooks 01–08 ทั้งหมดอธิบาย population ที่ถูก supersede
>
> **แนวทาง:** ตัดย่อหน้าให้เหลือสถานะปัจจุบัน แล้วย้ายประวัติไปไว้หัวข้อ “superseded history” หัวข้อเดียว

4.2 ต้องรอทรัพยากรภายนอก — วางแผนล่วงหน้าได้แต่ทำเองไม่ได้

งาน	ติดอะไร	แนวทาง / สิ่งที่ต้องเตรียม
A/B analyst triage-time study (≥15 analysts × 20 alerts, blinded)	ต้องมีผู้เข้าร่วมจริง และต้องผ่านคณะกรรมการจริยธรรมการวิจัยในมนุษย์	เตรียมชุด alert 2 กลุ่ม (hybrid / baseline) ให้พร้อมและ blind ไว้ล่วงหน้า · ร่างเอกสารขอจริยธรรม + แบบยินยอม · กำหนดตัวชี้วัดเวลาและความถูกต้องก่อนเก็บข้อมูล (ไม่ใช่หลังเห็นผล)
ส่ง LINE / Gmail จริง	sandbox ไม่มี outbound internet · Gmail OAuth2 เว้นว่างไว้โดยเจตนา	ทดสอบจากเครื่องที่ออกเน็ตได้ · ขอ OAuth2 client + refresh token แล้วใส่ใน notification/.env (ไม่ commit) · เส้นทาง LINE มี token จริงแล้ว เหลือแค่เน็ต
Kafka broker จริง + OpenCTI จริง กับ enrich.py	ยังไม่เคยต่อของจริงเลย · `kafka-python` ยังไม่ติดตั้ง	ติดตั้ง kafka-python · รัน stack ตามคำสั่งใน CLAUDE.md · **คาดว่า GraphQL query shapes จะต้องแก้** เพราะเขียนจากความรู้ 5.12.x โดยไม่เคยยิงจริง (query ผิดจะกลายเป็น "ไม่ match" ไม่ใช่ match ผิด จึงไม่อันตราย แต่ต้องตรวจ)
ตรวจคุณภาพ LLM เชิงภาษา	ต้องมีคนอ่านภาษาไทยตัดสินว่าคำอธิบายใช้งานได้จริงไหม	ทำหลังแก้ B9 · สุ่ม 20–30 เคสต่อหมวดสำคัญ · ให้คะแนนตามเกณฑ์ที่กำหนดไว้ก่อนอ่าน (ความถูกต้องของ entity · ความเหมาะสมของ remediation · ความชัดเจน)

4.3 สิ่งที่แก้แบบ "เลี่ยง" ไม่ใช่แก้ที่ต้นเหตุ

MTTD ค่าหลัก degenerate — ตอนนี้แก้ด้วยการตัด flow แรกออก

สภาพจริง: flow แรกของทั้ง 228 campaign มี behavioral vector เป็นศูนย์ทั้ง 12 คอลัมน์ (ถูกต้องทางกายภาพ) และกฎให้คะแนนเฉลี่ย 8.94 เทียบ threshold 0.03 □ ตรวจจับได้ทุกอัน □ MTTD = 0.0000 s

วิธีรับมือตอนนี้: รายงานค่าที่ตัด flow แรกของแต่ละ campaign ออก พร้อมอธิบายเหตุผล — ได้ตัวเลขที่แยกแยะได้ (c2_beacon 193 s · data_exfil 452 s)

แก้ที่ต้นเหตุจะทำอย่างไร: ให้ generator ตั้งค่า window features ของ flow แรก จากการแจกแจงของ BENIGN จริง แทนที่จะเป็นศูนย์ — แต่ต้องตัดสินก่อนว่า "ผู้โจมตีจากภายนอกที่เพิ่งปรากฏตัว" ควรมีค่า window เป็นศูนย์จริงหรือไม่ ซึ่งเป็นคำถามเชิงแบบจำลอง ไม่ใช่เชิงโค้ด

overlay ให้ค่า behavioral อ่อนกว่าข้อมูลจริงมาก

วัดได้: `conn_count_1m` ของ overlay สูงสุด **0.014** เทียบข้อมูลจริง **1.0** · `uniq_dport_count_1m` 0.32 เทียบ 1.0 — port scan สังเคราะห์อ่อนกว่าของจริงมาก บน feature ที่ Option A เพิ่มเข้ามาโดยตรง

ผลคือ ห้ามอ่านอัตราการตรวจจับบน overlay เป็นหลักฐานความสามารถ (เขียนกำกับไว้แล้ว)

แนวทางแก้: ปรับ PROFILES ให้ความเข้มของ window features ใกล้การแจกแจงจริง โดย fit จาก attack rows จริงของแต่ละหมวด แทนการตั้งค่าจากกลไกการโจมตีด้วยมือ

5. สิ่งที่แก้ไม่ได้ด้วยข้อมูลชุดนี้

กลุ่มนี้**ไม่ใช่งานค้าง** แต่เป็นข้อจำกัดเชิงโครงสร้างที่ต้องเขียนในเล่มเป็นข้อจำกัดของงาน

ข้อจำกัด	ตัวเลข / สภาพจริง	ทำไมแก้ไม่ได้
Bot ตรวจไม่ได้เลย	nested LOAO recall 0.000 · ทุกสมาชิกเกือบศูนย์	ไม่มีกฎรวมใดกู้คืนได้เพราะไม่มีสมาชิกไหนตรวจเจอ · ต้องการ feature หรือข้อมูลชนิดใหม่ ไม่ใช่กฎใหม่
สองหมวดไม่มี redundancy	FTP-Patator และ Web Attack - BF ขึ้นกับ RF ตัวเดียว · PortScan ขึ้นกับ AE ตัวเดียว	เป็นผลจากความสามารถของโมเดลแต่ละชนิด ไม่ใช่การตั้งค่า
M1c พังทั้งสองทาง	CICIDS→UNSW AUC 0.3220 (กลับทิศ) · UNSW→CICIDS AUC 0.5034 (สุ่ม)	สอง testbed ต่างกัน เครื่องมือโจมตีต่างกัน เก็บต่างปีกัน · เป็นผลการวิจัยที่ต้องรายงาน ไม่ใช่การทดลองที่ล้มเหลว
M1c วัดได้แค่ RF	IF/AE เข้าร่วมไม่ได้	behavioral features ต้องใช้ Source IP / Timestamp ซึ่ง CIC-UNSW-NB15 ไม่มีในไฟล์ ML-ready
in-dataset metric อิ่มตัว	RF val F1 0.9997	เป็นคุณสมบัติของ CICIDS-2017 เอง · แก้โดยใช้ zero-day LOAO เป็นตัวตัดสินแทน
PA-5220 log จริงไม่มี	อยู่นอกขอบเขตถาวร (ตัดสินใจ 25 ต.ค. 2569)	ไม่เคยได้รับข้อมูล · CICIDS-2017 เป็นชุดเทรนชุดเดียว
IF ถูกตัดจากการตัดสินหลัก	IF ดีที่สุดบน DoS Slowhttptest (0.839 เทียบ AE 0.241, RF 0.055) แต่ FPR 0.09–0.15	เป็น trade-off ที่วัดแล้วและเลือกแล้ว ไม่ใช่ข้อบกพร่อง · ต้องรายงานว่าเสียอะไรไป
hybrid แพ้ RF ตัวเดียวใน dataset	F1 0.9966 เทียบ 0.9995 · FPR แย่กว่า 10 เท่า	เป็น trade-off ที่เลือกเพราะชนะ zero-day · ส่วนต่างแคบพอที่ผู้อ่าน จะเลือก RF ตัวเดียวอย่างมีเหตุผลได้ ต้องเขียนตรงๆ

6. ลำดับงานที่แนะนำ

ลำดับ	งาน	เหตุผลที่จัดลำดับนี้	เวลา
1	**แก้ eval_llm_faithfulness.py ไป unified (B9)**	**บล็อกทุกอย่างที่เกี่ยวกับ LLM · ตัวเลข M2 ที่มีอยู่ยังอ้างไม่ได้**	**~1 ชม.**
2	**start Ollama + รัน M2 ใหม่ 100 alert**	**ได้ตัวเลข M2 ที่ตรงกับ pipeline ที่ deploy จริง**	**~45 นาที**
3	**ตรวจคุณภาพ LLM เชิงภาษาโดยคนอ่าน**	**layer เดียวที่โค้ดเสร็จแต่ไม่มีหลักฐานคุณภาพเลย · ทำได้โดยไม่ต้องรอใครภายนอก**	**ครึ่งวัน**
4	แก้ eda_sanity_check.py (B10)	ถูกเพราะเล่มอาจอ้างสถิติ EDA · ความเสี่ยงต่ำแต่ราคาถูก	~30 นาที
5	เตรียมชุด alert + เอกสารจริยธรรมสำหรับ A/B study	เป็นเส้นทางวิกฤต (critical path) ที่สุด เพราะรอคณะกรรมการ · เริ่มเตรียมได้เลย	1–2 วัน + รอ
6	ทดสอบ LINE / Gmail จากเครื่องที่ออกเน็ตได้	ปิดช่องว่าง “dry-run only” ของชั้น output	~2 ชม.
7	ต่อ Kafka + OpenCTI จริงกับ enrich.py	คาดว่าต้องแก้ GraphQL query shapes · ไม่บล็อกตัวเลขในเล่ม	ครึ่งวัน
8	จัดระเบียบ CLAUDE.md + ปรับ overlay profiles	งานคุณภาพเอกสาร/แบบจำลอง ไม่บล็อกการส่งเล่ม	~2 ชม.

ข้อสังเกตเรื่องลำดับ

งานที่ **รอคนอื่น** (A/B study ข้อ 5) ควรเริ่ม**เตรียมพร้อมกัน**กับข้อ 1–3 ไม่ใช่ทำตามลำดับ เพราะเวลารอคณะกรรมการจริยธรรมเป็นส่วนที่ควบคุมไม่ได้และยาวที่สุด

ข้อ 1–3 เป็นชุดเดียวกัน: ทำข้อ 2 ก่อนข้อ 1 จะได้ตัวเลขที่ต้องทึ่งอยู่ดี

สรุปสถานะเป็นตัวเลข

หมวด	จำนวน
ปัญหาที่พบและแก้แล้ว	14 ข้อ (A1–A5, B1–B8, C1)
ยังไม่แก้ · ทำเองได้	4 ข้อ (B9, B10, คุณภาพ LLM, เอกสาร)
ยังไม่แก้ · รอทรัพยากรภายนอก	4 ข้อ
แก้แบบเลี่ยง ยังไม่ถึงต้นเหตุ	2 ข้อ (MTTD flow แรก, overlay profiles)
ข้อจำกัดเชิงโครงสร้าง (รายงานในเล่ม)	8 ข้อ

ไฟล์หลักฐาน: reports/unified_val_metrics.csv · fusion_layer_loao_unified_or_comparison.csv · rf_behavioral_ablation_loao_report.txt · baseline_model_comparison.csv · siem_baseline_report.txt · cross_dataset_m1c_metrics.csv · mttd_metrics_excluding_first_flow.csv · shap_explainability_report.txt · models/fusion_config.json · models/llm_layer_config.json